Paged Decode Lab

基于 Triton 的分页 Decode Attention 实现、推理接入与性能边界分析

求职展示与 GitHub 开源候选说明

整理日期：2026-11-06
来源：本次远程只读采集快照；未重新运行 GPU 或模型。

摘要

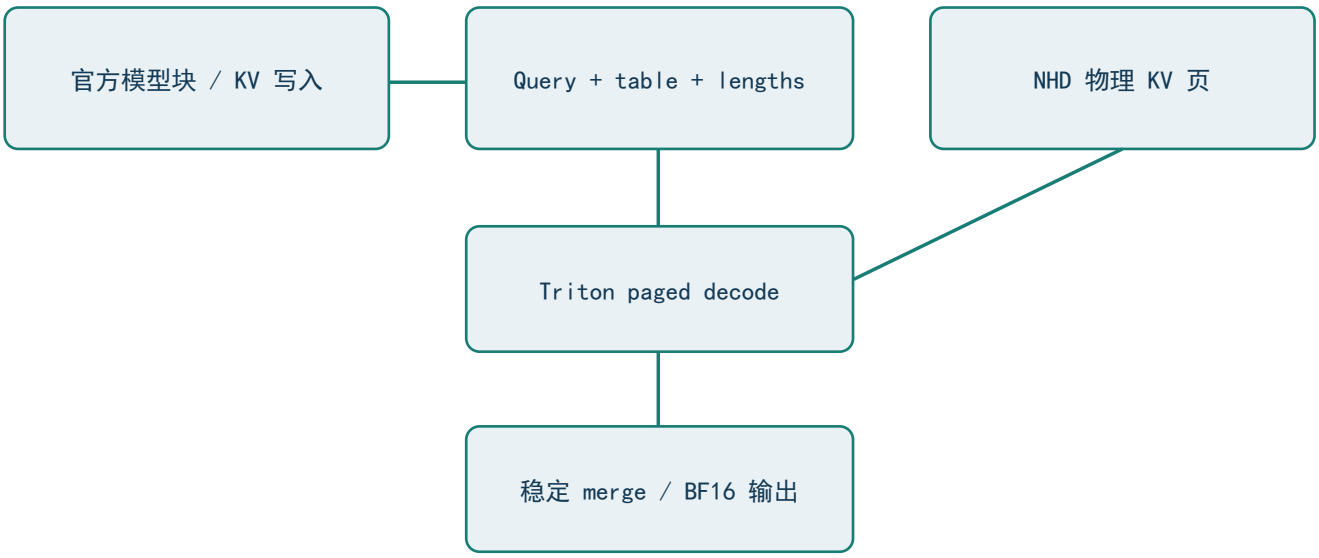
项目研究单 token decode 如何访问分页 KV Cache、如何通过 split-K 提高并行度，以及如何在固定容量和 CUDA Graph 中保持数值与资源正确。实现基础、split-K、Tensor Core 和容量 / LSE 对齐路径，并在固定 Qwen3.5-0.8B / 9B 上进行历史真实模型回归。

最新 D256 实验通过减少流水线阶段降低 shared 占用，恢复驱动允许的双 CTA 驻留上限。固定长上下文完整算子约加速1.25倍，短上下文约退化2.44%，模型端到端收益很小。本文同时保留收益、失败和复现缺口，避免把局部算子结果泛化成工业服务能力。

核心交付	范围
源码	自定义 kernel、运行时、官方模型适配、上游覆盖层
验证	历史 GPU / logits 证据；本轮 CPU、重建与统计重算
适用范围	单 GPU、文本、固定无 padding batch；学习与研究

01 问题、目标与系统架构

自回归生成每次只有一个 query token，却要读取完整历史 KV。连续数组的地址假设不能直接应用于分页缓存；小 batch 又可能没有足够 CTA。项目把分页寻址、归约并行度、浮点计算顺序和执行开销放在同一条可验证路径中。



路径	上游承担	本项目承担
nano-vLLM	模型、权重、prefill、KV写入、调度及Graph框架	固定基线的decode后端、workspace及接入校验
Qwen3.5 hybrid	官方模型块、Gated DeltaNet、RoPE、norm、MLP	full attention分页执行、稳定状态、Graph与实验callback

两个路径并列存在。Qwen3.5 runner 不是把模型完整移植进 nano-vLLM，也不提供连续批处理、多卡通信、抢占或图像输入。不能把上游能力作为个人原创成果。

02 分页寻址与稳定归约

输入 Q 的形状为[B,Hq,D]；KV为[Npages,256,Hkv,D]；table和lengths为int32。GQA把多个query heads映射至同一个KV head。

```
page = table[b, t // 256]
slot = t % 256
kv_head = h // (Hq // Hkv)
offset = ((page * 256 + slot) * Hkv + kv_head) * D + d
```

基础版由一个 CTA 处理序列中的一个query head。每次读取一块token，更新online softmax最大值m、分母l和加权和a：先用新最大值缩放历史状态，再累加当前块，保持FP32累加，最后转回BF16。零长度行返回零。

方案	中间状态	合并与代价
基础版	m / l / acc	无额外merge，但小batch长KV的并行度有限
固定1024 split-K	每区m / l / acc	稳定重缩放后合并；增加并行也增加workspace和kernel开销
容量匹配split-KV	normalized partial + LSE	固定容量决定分区；协议不同，不能复用其他后端成绩

逻辑位置与物理页不连续；分区边界也未必与256-token页边界重合。所有有效访问必须按逻辑位置查表，并用长度mask保护无效表项和NaN尾部。空分区不贡献概率，全部为空时不能产生NaN。

主要源码：kernels.py实现基础 / split / merge；runtime.py管理借用输出与预分配workspace；matched_splitkv.py和splitkv_plan.py实现容量与LSE协议。外部页表内容校验需显式进行，热路径的shape检查不能代替内容安全。

03 数值一致性与 CUDA Graph

attention容差内误差不保证greedy token一致。真实激活诊断发现：BF16 partial已经相同，FP32 local LSE仍可能因log实现与舍入顺序而不同，最终改变BF16输出或接近的logits argmax。

阶段	关键发现	处理
matched v1	容量 / normalized partial已对齐，local LSE仍有差异	保留失败并定位log协议
matched v2	控制快速log指令及合并顺序	已记录用例恢复对齐；非任意输入保证
四状态微内核	预先缩放状态阻断首项FMA收缩	显式传递未缩放state和alpha，保留FMA
S2实验	数值协议不变，只手动调整stages	重跑同套分页、模型与Graph回归

Graph生命周期

先固定batch、完整table宽度和最大容量；分配KV、输出、workspace及linear state；在capture之前编译、预热和布局预检。捕获完整文本decode forward，包含KV写入、linear state更新、lm_head。prefill和token选择仍在Graph外。

replay只更新稳定地址中的内容，不读取GPU标量决定Python分支。回归覆盖零上下文、无效页、NaN padding、内容修改、页映射翻转、跨页增长和多次replay；输出、partials和LSE按形状与dtype检查后比较字节。

最新shared_s2只在独立实验入口中启用，正式CLI的默认后端仍是FlashAttention；不支持的sm80 / D256 / 布局配置会报错，避免静默回退掩盖实验。

04 实验设置与验证层级

项目	设置与限制
硬件	A100-SXM4-80GB，sm80，108 SM；两模型分用两张GPU，CPU共享
软件	Torch2.6.0 / Triton3.2.0 / FA2.7.4.post1 / Transformers5.3.0；历史CUDA12.4
模型	Qwen3.5-0.8B与9B，revision固定；full attention D256；linear attention官方Torch fallback
算子矩阵	真实9B第3层第16步激活；上下文528/2064；36splits；两种unroll、五轮随机顺序，共480条
模型矩阵	batch1；输入512/2048；输出64；4后端×eager/Graph×5轮×2模型，共160条
数值	72项分页输出；每模型1920完整logits步骤和60次自由生成；性能输入各另1024步骤

计时区间

算子采用Graph unroll32/128、20次replay、五轮重复，主表取unroll128；包含partition+merge，workspace提前分配。固定真实张量反复访问为hot-cache诊断，不含模型或KV写入，不等同于kernel busy time。缩减grid只用于局部分区诊断。

模型wall调用没有逐步CUDA Event；另一次生成采集63个decode事件区间。JIT、预热与capture不计入。三组自定义workspace在native等全部配置中保留，因此峰值allocated显存不能解释为原生最小显存。

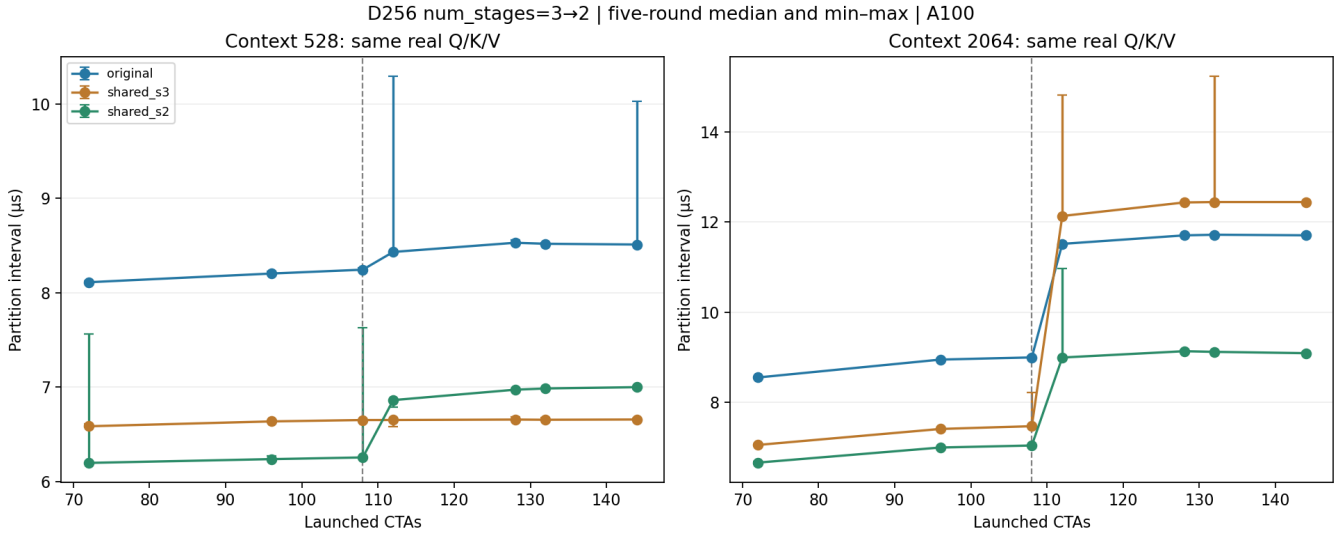
验证层级依次为CPU算法 / 协议、GPU算子、Graph replay、完整logits、独立greedy和性能；没有训练、模型效果排行榜或真实业务验收。本次公开整理只执行无GPU验证，历史GPU结果单独标注。

05 资源变化、收益与退化

配置	dynamic B	static B	regs	spill字段	CTA/SM上限
original	79232	0	255	16	2
shared_s3	79232	4352	255	8	1
shared_s2	77952	4352	192	0	2

S2 dynamic shared减少1280B。每CTA含驱动预留共83328B，两CTA为166656B，小于每SM167936B。驱动查询支持双CTA驻留；这不是achieved occupancy实测。寄存器和spill也随编译调度变化，不能把全部性能变化仅归因于容量。

上下文	完整S3 us	完整S2 us	同轮S3/S2中位数
528	10.7780	11.0369	0.9762（S2退化约2.44%）
2064	16.6610	13.3474	1.2483（S2获益）



图：同一真实张量的partition grid对照，五轮中位数及min/max，非置信区间。完整算子比值取同轮配对，不是两个独立中位数之比。Graph模型wall比值仅0.9984 – 1.0015，不能把算子约1.25倍写成模型吞吐提升。

06 迭代过程与未采用方案

阶段	相对变化 / 解决的问题	验证与最终状态
基础 → split-K	增加KV分区并行，减少单CTA长循环	FP32参考；历史模型仍有argmax分歧，显式保留
TC ordered → TC split-K	引入Tensor Core及有序分母	v2-gather因API缺失编译失败；固定1024版9B长输入仍失败
matched v1 → v2	容量规划、normalized partial/LSE及快速log	真实激活诊断＋logits；v2正式CLI，v1快照保留
warps / late V / IR	检查并行度、临时量、布局与存活	独立实验；部分计时不收敛，未全部采用
四状态 → D256 S3	保序归约微内核接入分页partition	槽位 / FMA / 数值通过；长上下文因资源门槛退化
D256 S3 → S2	stages3→2降低dynamic shared	同套回归，长输入改善、短输入退化，保留显式配置
本次候选整理	来源映射、派生摘要、重建、README和PDF	发布工具与文档变化；核心算法变化为无

完整迭代文档按模型 / 适配器、输入、工具执行层、核心算法、评测及发布分别记录。Qwen3到Qwen3.5是模型适配路线变化，不能把不同模型或不同测试集成绩拼成升级曲线。发布包修订不是算法版本升级。

没有项目Git历史可供恢复，因此不虚构tag、commit或迭代日期。源码快照只用于审计，不是可独立运行的全部旧版本。早期负结果按远程报告复核，本次没有重跑全部历史实验。

Nsight多种探测超时 / 未捕获有效kernel计数器，不能写成已证实权限拒绝。旧控制路径新编译.text不完全相同，原因未定；禁止跨campaign绝对时延归因。

07 演示与分层复现

演示先从逻辑页映射和NumPy reference开始，再解释kernel、split合并、Graph和资源门槛。没有GPU时明确展示历史证据，不用模拟输出冒充真实推理。全部命令从候选根目录执行。

Windows PowerShell：无GPU示例

```
python -m venv .venv-cpu

.\.venv-cpu\Scripts\python.exe -m pip install -e ".[test]"

.\.venv-cpu\Scripts\python.exe examples/cpu_attention.py

.\.venv-cpu\Scripts\python.exe release/rebuild_upstream.py

.\.venv-cpu\Scripts\python.exe release/check_cpu.py
```

完整可复制命令及每步退出码检查见README。基线重建默认联网；已有固定ZIP时用--archive离线。候选不重复分发完整上游源码。

Linux终端：已准备GPU依赖和模型后

```
source tools/env.sh

python tools/qwen35.py --model models/Qwen3.5-0.8B \

--backend triton_matched --mode graph --output results/demo-new

python tools/resident_experiment.py --task correctness \

--output results/correct-new
```

下载模型必须先于source env.sh，因为该脚本开启离线模式。模型revision及权重SHA256在configs/models.json，安装版本在requirements-qwen35.txt。S2实验另用resident_experiment或benchmark_fragment_resident_models，不是qwen35的后端选项。

输出路径必须不存在。真实GPU命令由使用者主动执行；本轮未安装系统依赖、运行模型、训练或启动GPU任务。更完整的Linux安装、两模型和五轮性能命令见docs/REPRODUCE.md。

08 来源、公开范围与检查记录

远程为事实来源：只读盘点5857文件，已扫描文件合计2438308723B；模型、环境、缓存等未遍历，因此不知道项目总大小。按白名单采集725文件、10902819B，逐文件SHA256通过，与旧本地同路径全部一致。

公开版保留原字节源码、必要快照、配置、测试和上游覆盖层；不公开原日志、UUID/PID、服务器路径、生成响应、权重或真实KV大张量。派生摘要通过字段白名单提取，记录原SHA、提取规则及公开文件SHA；不是原始证据的替身。

检查层	本次结论
原字节与版本	私有审查包及725文件核验；核心源码保持字节
上游与CPU	固定ZIP离线重建26文件；176项CPU检查通过
统计	480条算子和160条模型公开记录重算，与远程报告一致
GPU / 模型	本轮未运行，使用有来源的历史结果
新环境 / 业务	未安装完整新GPU环境，无真实业务 / 生产验收

重要缺口

原真实张量算子计时需要未公开KV快照，旧采集命令还依赖历史输入记录；不能宣称外部读者可直接完全复跑。可以离线重算统计，并在自己环境重新采集新实验。没有新的硬件计数器、新模型下载可用性检查或当前GitHub URL。

首轮CPU检查遇到Windows临时目录权限问题，修正的是新增release检查脚本；最终176项通过。继承源码的空白、换行及补丁上下文没有为消除工具提示而修改。PDF和最终ZIP检查详见docs/VALIDATION.md及私有审查记录。

09 贡献归属、参考资料与展示要点

贡献与许可

新增kernel、runtime、后端集成和实验工具使用AI辅助完成，延用原项目MIT许可。nano-vLLM保留MIT版权；Qwen模型及Transformers模型块遵循各自上游许可。未复制分发FlashInfer代码，不把官方linear attention、prefill或调度能力归为自研。

参考资料（上游固定来源与学习资料）

nano-vLLM: https://github.com/GeeeekExplorer/nano-vllm ; 固定提交 bb823b3e06983d71485a8e1f23715ebd87d98ef8。

Triton fused attention tutorial: https://triton-lang.org/main/getting-started/tutorials/06-fused-attention.html 。

FlashAttention论文: https://arxiv.org/abs/2205.14135 。

FlashAttention源码参考版本: v2.7.4.post1；softmax.h、utils.h、flash_api.cpp；BSD-3-Clause。

FlashInfer: https://github.com/flashinfer-ai/flashinfer 。用于理解工程取舍，不随项目分发。

Qwen官方仓库: https://huggingface.co/Qwen/Qwen3.5-0.8B 与 https://huggingface.co/Qwen/Qwen3.5-9B 。revision和权重摘要见configs/models.json。

Transformers官方Qwen3.5模型块: transformers/models/qwen3_5/modeling_qwen3_5.py，5.3.0，Apache-2.0。

选题流程参考: https://github.com/LiuMengxuan04/shushu-internship-tool 。未复制其脚本或虚构评分。

面试应能解释

逻辑token如何映射到物理KV页；split-K何时增加并行、何时多出归约成本；为什么log与FMA改变数值协议；Graph需要稳定哪些地址；驱动驻留上限与实际occupancy有什么区别；为什么attention算子加速没有等比例改善端到端。

GitHub仓库由用户手动创建和上传。本次没有自动commit、push或发布；真实姓名、邮箱和仓库地址未猜测。上传工具保留现有Git历史和修改，检查失败时停止，不使用reset --hard或force push。